

深度學習應用於屋舍震後損害程度評估

實習生：黃柏翰

專案經理：蔡政儒

1. Introduction

臺灣位於環太平洋地震帶上，地震發生頻繁又不可預測，對人民生命財產安全構成嚴重威脅。歷次地震災害顯示，房屋結構損害後的迅速且準確評估對於災後應急處置、結構修復與民眾安全保障十分關鍵。然而傳統的評估方式通常仰賴技師現場勘查，過程耗時且高度仰賴專業人員的經驗與主觀判斷，不僅效率低下，也可能因人為因素產生誤差。

為改善上述問題，本研究旨在開發一套基於深度學習的行動應用系統，協助一般民眾於震後快速評估建築結構損害程度。此系統透過使用者拍攝建築物構件（如樑、柱、牆）受損影像，結合先進的物件偵測模型（YOLOv11）[1]自動辨識結構表面常見的損害類型，包括裂縫（Crack）、混凝土剝落（Spalling）及鋼筋裸露（Exposed Rebar）等，並進一步將損害嚴重程度分級為嚴重損害（A 級，建議立即撤離）、需專業維修（B 級）與輕微損害（C 級）三種等級。

當前目標是基於核心技術框架下，結合分類與邏輯演算法以提升整體評估效率與精度。

2. Methodology

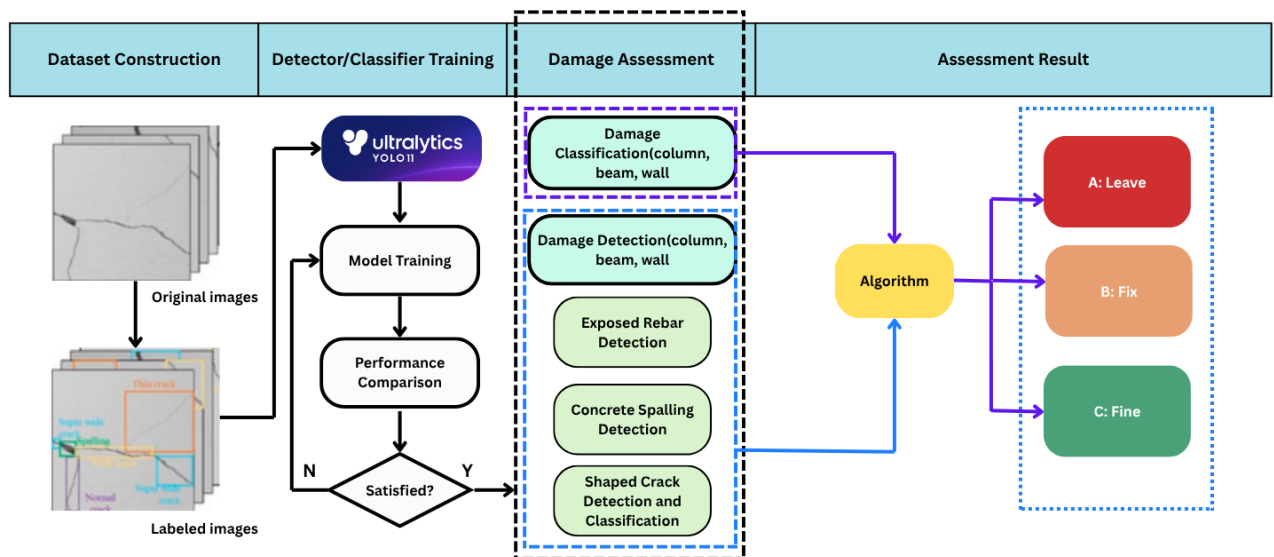
本研究旨在建立一套基於深度學習的震後房屋損害辨識與評估系統，整體架構分為資料收集與預處理、模型架構與訓練方法，以及損害程度評估與分類三大部分。其中第三部分包含一套演算法[2]，以整合各模型輸出結果並做出最終損害等級判斷。

2.1 資料收集與預處理

資料來源主要包括慈濟所提供之實際場景中收集之震損影像，以及 Roboflow 等影像資料庫，涵蓋梁、柱與牆三種結構元件。資料中標註的裂縫種類又根據常見的形狀再細分成不同類別，如水平裂縫、垂直裂縫、對角裂縫等[3]。

資料經過尺寸調整（Resize）與資料增強（Data augmentation）後，以 8:1:1 比例分為訓練集、驗證集及測試集，用於模型的訓練與評估。

2.2 模型架構與訓練方法



圖一、研究架構圖

模型採用三階段式架構：

2.2.1 第一階段：損害物件辨識模型

本階段模型使用 YOLOv11 進行物件偵測，以辨識三大損害類型(鋼筋裸露、混凝土剝落、裂縫)的位置與範圍，輸出每張照片中的損害位置資訊作為下一階段分類之輸入。

2.2.2 第二階段：損害分類模型

此階段輔助第一階段未能辨識出的影像區域進行更細緻的損害分類與處理：

- **裂縫分類模型 (Crack Classification)**：針對裂縫進一步分類，區分 X 型、V 型、對角型、水平與垂直裂縫等類別，並依照不同構件 (梁、柱、牆) 進行訓練。
- **災害分類模型 (Damage Level Classification)**：協助判別各構件在不同等級災害下的破壞狀態。
- **裂縫分割模型 (Crack Segmentation) [4]**：確認並標註出更完全之損害區域。
- **混凝土剝落與鋼筋裸露分割模型 (Spalling and Rebar Segmentation)**：辨識並標註混凝土剝落區域，並區分是否伴隨裸露鋼筋。

2.3 損害評估演算法與分類判斷

2.3.1 第三階段：特徵萃取與準則比對演算法 (Feature Extraction and Criteria Matching Algorithm)

為將模型辨識輸出的各項結果，進一步整合為具體損害評估與分類之輸出，故發展一套初步的「準則映射演算法」(Criteria Mapping Algorithm)，根據上述

模型之輸出標籤（如：裂縫類型、鋼筋裸露、剝落等），依照預先定義的損害準則進行分類判斷。

具體流程如下：

- 每張影像之損害辨識結果會對應特定標籤 (criteria labels)，依結構元件類別（梁、柱、牆）分別設定分類準則。
- 準則共分為 A、B、C 三級，如牆結構中若辨識出裸露鋼筋或大面積剝落，即直接歸為最高級（A 級）；若出現連續型裂縫（如連續垂直或水平裂縫），則歸為中度損害（B 級）；若僅出現非連續、小型裂縫，則歸類為輕微損害（C 級）。

現階段之演算法具體執行方式為：

- 步驟 1：收集模型輸出之各損害標籤（鋼筋裸露、剝落、裂縫種類等）。
- 步驟 2：根據結構元件類別（梁、柱、牆），查詢預定義之準則表格進行損害級別映射。
- 步驟 3：根據映射結果，分類至損害等級 A、B 或 C。

2.3.2 損害程度分類標準 (Damage level criteria)

以牆結構為例，各類損害之分類標籤如下：

- 嚴重（A 級）：
 - 裸露鋼筋（Exposed rebar）
 - 大面積混凝土剝落（Huge Spalling）
- 中度（B 級）：
 - X 型(X-Shape)或 V 型(V-Shape)裂縫
 - 連續性(Continuous)裂縫
- 輕微（C 級）：
 - 不連續(Discontinuous)裂縫
 - 小型細微(Minor)裂縫

2.3.3 分類結果輸出


演算法依據各模型輸出之損害標籤及並參考上述分類標準，最終將建築物之損害狀況分成以下三級：

- **A 級 (leave)**：房屋損害嚴重且結構安全堪慮，需立即撤離。
- **B 級 (fix)**：房屋結構中度損害，需專業修復處理。
- **C 級 (fine)**：輕微損害，不影響房屋結構安全，可由屋主自行評斷是否修復。

3. Preliminary Results

3.1 損害偵測模型 (Damage Detection)

初步訓練以 300 個 Epoch 完成，採用多尺度 (multi-scale) 超參數以提升模型泛化能力。從評估指標來看，模型的 **mAP@0.5** 由訓練初期的 43% 提升至目前的 98%(圖一)，顯示模型在三類損害偵測任務上的整體表現已達到高水準。然而，根據 confusion matrix 分析(圖二)可發現，模型仍存在 precision 的不穩定現象，尤其在混凝土剝落類別與鋼筋裸露類別之間存在部分混淆。原因可能與資料中損害類型分布不均、部分剝落損害伴隨鋼筋裸露，導致模型難以精確區分有關。



圖二、損壞偵測模型評估指標



圖三、Confusion Matrix

3.2 裂縫分割與分類模型 (Crack Segmentation and Classification)


3.2.1 裂縫分割模型 (Crack Segmentation)

經過 100 個 Epoch 的訓練，使用 cosine 學習率與多尺度等超參數。模型訓練後之評估指標為：

- mAP@0.5 per class: **61.49%**

- mAP@0.5:0.95 per class: **16.93%**
- Precision per class: **73.12%**
- Recall per class: **63.36%**

從以上結果可見，模型在 mAP@0.5 上有合理表現，但在更嚴格的 mAP@0.5:0.95 下明顯降低。Precision 比 Recall 高的情況則說明了模型趨於保守，進而導致對於裂縫分支末端、模糊邊界偵測不完整的問題，如圖三所示。




圖四、分割實際影像(左圖為正確答案，右圖為預測結果)

3.2.2 裂縫分類模型 (Crack Classification)


本階段針對不同結構構件的裂縫進行分類：

- **牆面裂縫分類 (11 類)**：整體分類結果較穩定，多數類別達到較高的分類準確度。但從 confusion matrix 可以觀察到，大、小範圍裂縫間存在混淆。而 spalling-like cracks 幾乎無法辨識，只有 1 筆被正確分類，顯示該類別樣本數不足，或外觀特徵太接近其他類型。




圖五、牆面裂縫分類 Confusion Matrix

- **柱裂縫分類（7類）：**Horizontal_large 幾乎無法正確預測，可能與定義邊界模糊、訓練樣本不足有關。這也進一步造成在判斷「裂縫形狀較複雜」或「尺度差異不明顯」等情況時有所困難。



圖六、柱裂縫分類 Confusion Matrix

- **梁裂縫分類（4類）：**面臨 Web 型裂縫誤判率偏高的問題，此類裂縫與其他類型相比未有明顯特徵且形態上差異較大，導致模型泛化能力受限。




圖七、梁裂縫分類 Confusion Matrix

3.3 災害分類模型 (Damage Level Classification)

負責損害等級 (A、B、C) 的輸出，根據目前 confusion matrix 的結果分析 (圖七)：

- **A 級 (嚴重)**：模型對「裸露鋼筋」與「大面積剝落」有較高敏感性與正確率，但偶爾會誤將部分結果判斷為 C 級。
- **B 級 (中度)**：在輕微 (C 級) 或嚴重損害 (A 級) 間偶有混淆情形。
- **C 級 (輕微)**：輕微裂縫 (小型、不連續) 分類準確度相對穩定，但在特定情況下 (如視角、光影變化) 仍可能提升誤判風險 (圖九)。

此階段的分類結果與演算法設定高度相關，因為現階段之分類演算法僅透過模型之標籤邏輯進行簡單映射，尚未納入細緻量化指標 (如裂縫長度、寬度、剝落面積)。



圖八、災損程度分類 Confusion Matrix



圖九、分類實際影像(左圖為正確答案，右圖為輸出結果)



圖十、特定情況示意圖

4. Future Works

目前的損害分類仍較為初步，僅仰賴深度學習模型辨識出的損害類別與簡單的準則映射分類方法，尚未充分考慮裂縫的量化特徵。因此在未來研究中會導入 OpenCV 等影像分析工具，從裂縫的骨架分析、曲率計算、主方向分析，到裂縫的長度、寬度、面積與分形維度(Fractal Dimension)等更精細的特徵，進行深入的量化分析[4, 6]。

此外，在裂縫分類模型中所面臨的影像相似性及標註主觀性問題，也值得在未來持續關注與改善。現階段裂縫分類模型在某些裂縫類別的辨識上仍存在誤判問題，例如 Web 型裂縫與垂直或對角裂縫常有混淆，以及部分裂縫形態相似度較高。為克服這些問題，後續將重新整合或合併稀少或相似的裂縫類別，透過資料平衡來降低模型的混淆。也將考慮使用具有更佳泛化能力的預訓練 backbone 模型，例如 ResNet 或 Vision Transformer(ViT)[7, 8]，甚至進一步加入 Attention 機制，以改善模型對裂縫之間微小差異的辨識能力，進而提高整體的分類準確度與穩定性。

而災害程度分類演算法會考慮透過特徵量化（如前述的裂縫特徵量化分析）並搭配交叉驗證（Cross-stage Refinement）[9]等方式，藉由更多元的特徵與更精細的邏輯規則，來提升整體系統的實用性與可靠度，使其能精確地應用於實務震災損害評估場域。

5. References

- [1] R. Khanam and M. Hussain, ‘YOLOv11: An Overview of the Key Architectural Enhancements’, Oct. 23, 2024, *arXiv*: arXiv:2410.17725. doi: 10.48550/arXiv.2410.17725.

- [2] C. Fan, Y. Ding, X. Liu, and K. Yang, ‘A review of crack research in concrete structures based on data-driven and intelligent algorithms’, *Structures*, vol. 75, p. 108800, May 2025, doi: 10.1016/j.istruc.2025.108800.
- [3] L. Guo, R. Li, B. Jiang, and X. Shen, ‘Automatic crack distress classification from concrete surface images using a novel deep-width network architecture’, *Neurocomputing*, vol. 397, pp. 383–392, July 2020, doi: 10.1016/j.neucom.2019.08.107.
- [4] S. Ataei, S. Adibnazari, and S. T. Ataei, ‘Data-driven Detection and Evaluation of Damages in Concrete Structures: Using Deep Learning and Computer Vision’, Jan. 21, 2025, *arXiv*: arXiv:2501.11836. doi: 10.48550/arXiv.2501.11836.
- [5] M. Flah, A. R. Suleiman, and M. L. Nehdi, ‘Classification and quantification of cracks in concrete structures using deep learning image-based techniques’, *Cement and Concrete Composites*, vol. 114, p. 103781, Nov. 2020, doi: 10.1016/j.cemconcomp.2020.103781.
- [6] M. Su, J. Wan, Q. Zhou, R. Wang, Y. Xie, and H. Peng, ‘Utilizing pretrained convolutional neural networks for crack detection and geometric feature recognition in concrete surface images’, *Journal of Building Engineering*, vol. 98, p. 111386, Dec. 2024, doi: 10.1016/j.jobbe.2024.111386.
- [7] A. Shakarami, L. Nicole, R. Cappellesso, A. P. D. Tos, and S. Ghidoni, ‘DepViT-CAD: Deployable Vision Transformer-Based Cancer Diagnosis in Histopathology’, July 14, 2025, *arXiv*: arXiv:2507.10250. doi: 10.48550/arXiv.2507.10250.
- [8] T. Shi and H. Luo, ‘Deep learning for automated detection and classification of crack severity level in concrete structures’, *Construction and Building Materials*, vol. 472, p. 140793, Apr. 2025, doi: 10.1016/j.conbuildmat.2025.140793.
- [9] Y. Liu *et al.*, ‘Crowd Counting Via Cross-Stage Refinement Networks’, *IEEE Transactions on Image Processing*, vol. 29, pp. 6800–6812, 2020, doi: 10.1109/TIP.2020.2994410.